

基础软件开发技术实践

智能软件工程实验报告

实验五：针对大模型生成代码的代码审查

姓名	请输入姓名	院系	请输入院系
学号	请输入学号	任课教师	刘佳琨
指导教师	刘佳琨	实验地点	请输入实验地点
实验时间	请输入实验时间		
实验得分		研讨得分	
报告得分		实验总分	

一、实验目的

完成本实验后，学生应能够：

- 1. 理解 AI 生成代码与人类编写代码之间的差异。
- 2. 掌握 AI 生成代码数据集的构建与筛选方法。
- 3. 能够利用实验二、实验三和实验四构建的代码审查模型分析 AI 生成代码。
- 4. 掌握不同代码审查模型在 AI 生成代码上的性能评估方法。
- 5. 理解 AI 生成代码给代码审查带来的新挑战。
- 6. 能够分析不同模型在 AI 生成代码场景下的优缺点。

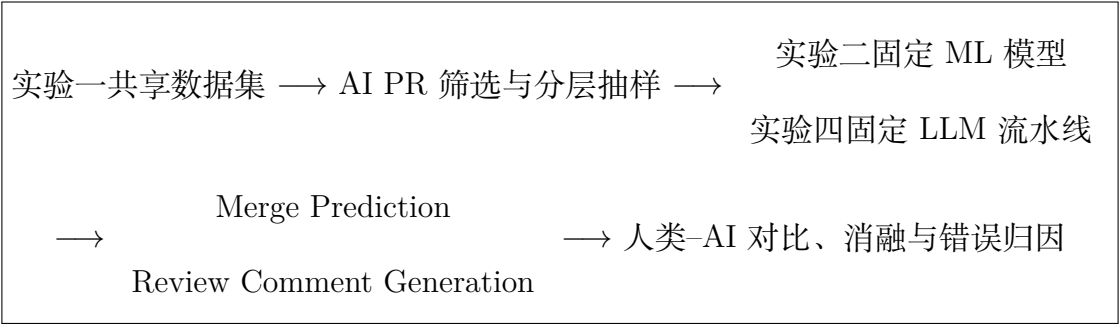
二、实验内容

2.1 研究设计与总体框架

本实验考察代码审查模型从人类代码迁移到 AI 生成代码后的性能变化。研究包含两个任务：Merge Prediction 根据 Pull Request (PR) 预测其最终合并状态；Review Comment Generation 根据代码改动生成一条具体、可操作的行内审查意见。两项任务共享实验一构建的五仓库数据集，并分别复用实验二的传统机器学习模型和实验四的大语言模型 (LLM) 流水线。

评估采用固定模型迁移协议。传统机器学习分支加载实验二保存的特征定义、标准化器和模型权重；LLM 分支沿用实验四的上下文组织、Prompt、推理参数与输出解析。AI PR 用作测试集，人类代码与 AI 代码的性能差由统一推理协议给出。

实验流程依次完成 AI PR 筛选、任务样本构造、模型推理和结果分析。人类代码 held-out test 提供原始性能锚点，按仓库和合并标签分层抽取的人类样本提供受控对照。结果分析覆盖主性能、上下文敏感度、审查过程特征消融和错误案例四条证据链。



2.2 数据与评估队列

实验一根据 bot 作者、commit 或 PR 正文中的 Co-authored-by 模式、AI 工具文本提示和相关标签生成 is_ai_code 标记，并保留每条标记的触发信号。五仓库数据集中共有 294 个 AI 标记 PR。本实验按任务输入和真值要求构造三个评估队列：

- (1) **AI 合并预测池：**保留 is_ai_code=True 且至少含一个具有 patch 的 Python 文件的 PR，共 253 条，其中 187 条已合并、66 条未合并。
- (2) **AI 审查意见生成池：**保留至少含一条顶层行内审查意见的 AI PR，共 72 条。每个 PR 取时间最早的非回复行内意见作为唯一参考文本，与实验四保持相同真值口径。
- (3) **匹配人类对照组：**从实验二 held-out test 集按 repo×is_merged 分层抽取 50 条。分层容量不足时，剩余名额按 AI 分布重新分配。最终对照组正类率为 66%，AI 分类样本正类率为 74%。

LLM 合并预测从 253 条 AI PR 中按仓库和合并标签分层抽取 50 条，审查意见生成使用全部 72 条 AI PR。生成任务沿用实验四的 50 条人类测试样本作为对照。所有抽样使用随机种子 42，样本键随实验结果一并落盘。

2.3 传统机器学习评估

传统机器学习分支评估 SVM、Random Forest (RF)、XGBoost 和 LightGBM。每个 PR 由 AST/CFG 结构特征、代码统计特征、文本统计特征以及 PR 标题与正文的 TF-IDF 表示组成。实验二保存了 50 个 tfidf_* 特征列，本实验据此恢复固定词表和 IDF，并对 AI 与人类对照文本执行 transform。重建特征与实验二原矩阵的最大绝对差为 2×10^{-16} 。

特征列按实验二保存的顺序排列，并由原标准化器完成变换。pre-review 特征描述审查开始前的 PR，构成主评估设置；full 特征加入评论数、审查轮次等过程变量，用于分析后验信息对结果的影响。四个模型分别在 253 条 AI PR 和 50 条匹配人类 PR 上运行，结果与实验二 208 条人类 held-out test 的指标对齐。

2.4 大语言模型评估

LLM 分支使用 `deepseek-v4-flash`，并在 16 个上下文-Prompt 条件下执行两个任务。C1 输入 Diff；C2 加入 PR 标题与描述；C3 加入 Commit Message；C4 同时加入 PR 描述和 Commit Message。P1-P4 分别对应 Zero-shot、Few-shot、Chain-of-Thought (CoT) 和 Role-based Prompt。Few-shot 示例来自实验四的人类训练集。

分类输出采用包含 `reasoning` 和 `decision` 的 JSON，决策标签为 `MERGE` 或 `REJECT`；生成输出采用包含 `comment` 的 JSON。分类温度设为 0，生成温度设为 0.3。语义缓存以任务、上下文、Prompt、PR 键和内容哈希联合索引。分类任务记录 1600 次推理，生成任务记录 1952 次推理。

表 1 LLM 实验矩阵。每个上下文与每种 Prompt 交叉组合，分别执行合并预测和审查意见生成。

维度	编号	实际输入或策略
上下文	C1	Diff
上下文	C2	Diff + PR 标题与描述
上下文	C3	Diff + Commit Message
上下文	C4	Diff + PR 标题与描述 + Commit Message
Prompt	P1	Zero-shot
Prompt	P2	Few-shot
Prompt	P3	Chain-of-Thought
Prompt	P4	Role-based

2.5 评价指标与分析设计

Merge Prediction 以“已合并”为正类，报告 Accuracy、Precision、Recall 和 F1，并在 Precision-Recall 平面上与恒预测正类基线比较。正类率为 p 时，该基线的 Precision、Recall 和 F1 分别为 p 、1 和 $2p/(1+p)$ 。AI 分类池的 $p = 0.739$ ，对应基线 F1 为 0.850。

Review Comment Generation 报告 corpus BLEU、ROUGE-1、ROUGE-2 和 ROUGE-L。BLEU 使用 0–100 量纲，ROUGE 使用 0–1 量纲。这些指标分别度量生成意见与参考意见的 n -gram 和最长公共子序列重合。

分析围绕三组比较展开。首先计算 AI 相对人类 held-out test 和匹配对照的逐模型性能差。随后对每个上下文在四种 Prompt 上求均值，并以

$$G_m = \frac{1}{4} \sum_{p=1}^4 m(C4, P_p) - \frac{1}{4} \sum_{p=1}^4 m(C1, P_p)$$

度量从 C1 到 C4 的上下文增益。最后从 LLM 分类错误中抽取五个不同 PR，结合 diff 检查错误方向与代码特征。过程特征消融、上下文增益和错误案例共同解释主性能变化。

2.6 实现与复现

实验使用 Python 3.12 和 uv 管理环境。data.py 与 sampling.py 构造评估队列，ml_features.py 与 ml_predict.py 完成传统机器学习推理，run_llm.py 编排 LLM 条件，evaluate.py 与 analysis.py 汇总指标和案例，nature_viz.py 导出 SVG、PDF 和 600 dpi PNG 图。固定随机种子、落盘样本和语义缓存保证各阶段输入一致。

三、实验结果

要求：将实验获得的结果进行描述，基本内容包括：

3.1 AI 生成代码数据集统计

实验一的 294 个 AI 标记 PR 形成了两个任务队列。合并预测队列包含 253 条 PR，其中 187 条已合并、66 条未合并，正类率为 73.9%；仓库分布为 pandas 135 条、Home Assistant 52 条、Airflow 47 条和 Transformers 19 条。审查意见生成队列包含 72 条带行内评论真值的 PR，覆盖五个仓库。LLM 分类使用 50 条分层 AI 样本和 50 条人类对照，标签比例分别为 37:13 和 33:17（表 2）。

表 2 实验五数据集统计。AI 分类池用于传统机器学习全量评估；LLM 分类使用其中的固定分层子样本。

集合	总数	已合并	未合并	合并率	用途
AI 合并预测池	253	187	66	73.9%	ML 全量测试
AI 分类分层样本	50	37	13	74.0%	LLM 合并预测
匹配人类分类对照	50	33	17	66.0%	ML/LLM 受控对比
AI 审查意见生成池	72	52	20	72.2%	LLM 意见生成
人类生成锚点	50	44	6	88.0%	复用实验四结果

3.2 传统机器学习的合并预测结果

pre-review 结果显示三个树模型在 AI 代码上出现一致的性能下降。RF 的 F1 从人类 test 的 0.813 降至 0.585，XGBoost 从 0.798 降至 0.594，LightGBM 从 0.804 降至 0.630；相对匹配人类对照的差值分别为 -0.277、-0.218 和 -0.137。三个模型的 AI Recall 为 0.460–0.519，大量已合并 PR 被预测为未合并（表 3）。

表 3 pre-review 特征下的 Merge Prediction 结果。人类 test 和匹配对照列报告 F1；AI 列同时报告 Accuracy、Precision、Recall 与 F1。

模型	人类 F1	对照 F1	AI Accuracy	AI Precision	AI Recall	AI F1
SVM	0.810	0.800	0.723	0.751	0.936	0.833
RF	0.813	0.862	0.518	0.804	0.460	0.585
XGBoost	0.798	0.812	0.530	0.821	0.465	0.594
LightGBM	0.804	0.767	0.549	0.802	0.519	0.630

SVM 呈现不同的预测模式：AI F1 为 0.833，比人类 test 高 0.023，Recall 为 0.936，Precision 为 0.751。AI 队列正类率为 73.9%，恒预测“合并”的理论 F1 为 0.850；SVM 的 Precision–Recall 位置接近这一基线，表明其高 F1 主要由合并偏向驱动。full 特征下，四个模型的 AI F1 集中在 0.665–0.694，均低于人类 test 的 0.857–0.870（图 1）。传统模型在人类代码上学习的特征–标签关系在 AI 代码上发生了明显变化。

Most human-trained models lose merge-prediction power on AI code




图 1 传统机器学习模型在人类代码、AI 代码与匹配人类对照上的合并预测 F1。a, pre-review 特征；b, 包含审查过程变量的 full 特征。蓝、红、绿分别表示实验二人类 held-out test、AI 代码和匹配人类对照。RF、XGBoost 和 LightGBM 在 AI 侧的 pre-review F1 下降，full 设置下四个模型的 AI F1 均低于两个人类锚点。图中为单次固定划分的点估计，不含误差条。

3.3 LLM 合并预测：高 F1 与类别偏向

16 个上下文-Prompt 条件呈现稳定的高 Recall 模式。AI Accuracy 为 0.72–0.76, F1 为 0.837–0.860, 平均 F1 为 0.853；人类侧平均 F1 为 0.799。AI Precision 为 0.735–0.766, Recall 为 0.973–1.000, 平均 Recall 达到 0.985。模型几乎总是预测“合并”，高 F1 与 AI 队列的正类占比共同形成。所有条件的 JSON 解析错误率均为 0，输出解析未改变这一分布。

图 2a、b 将这一现象展开到全部 16 个条件：F1 保持在 0.84–0.86，Recall 同步接近 1。图 2c 的 ROUGE-L 变化范围同样较窄。Precision、Recall 与多数类基线共同给出了比单一 F1 更完整的模型行为描述。

AI-side landscape: F1 looks strong, but recall is saturated (the artifact)




图 2 AI 代码上的 LLM 16 条件结果。行对应 C1 Diff、C2 Diff+PR 描述、C3 Diff+Commit 和 C4 全部上下文，列对应 Zero-shot、Few-shot、CoT 和 Role-based Prompt。**a**, Merge Prediction F1; **b**, Merge Prediction Recall; **c**, Review Comment Generation ROUGE-L。分类 F1 为 0.84–0.86，但 Recall 接近 1，揭示了偏向预测“合并”的现象；生成 ROUGE-L 整体较低且条件差异有限。

3.4 匹配对照与类别不平衡诊断

按仓库和合并标签分层后，三个树模型的性能差仍然存在。AI 侧 RF、XGBoost 和 LightGBM 的 F1 分别比 held-out 人类对照低 0.277、0.218 和 0.137，SVM 高 0.033（图 3a）。对照样本来自实验二 test 集，F1 差值建立在独立的人类样本上。

Precision–Recall 平面进一步区分了两类迁移行为（图 3b）。SVM 与 16 个 LLM 条件靠近恒预测“合并”的理论位置 (0.739, 1.000)，表现为召回饱和；三个树模型位于 Precision 约 0.80、Recall 约 0.46–0.52 的区域，表现为召回下降。两类模型沿相反方向偏离了均衡判别状态。

Tree-model drops persist (a); high F1 can reflect class imbalance (b)




图 3 分布感知对照与类别偏向诊断。**a**, pre-review 设置下 AI 代码与 held-out 分层人类对照的 F1 哑铃图；负值表示 AI 侧低于对照。**b**, AI 侧 Precision–Recall 平面；黑色星号是按 AI 正类率计算的恒预测“合并”基线，红色点/三角为传统机器学习模型，紫色空心方块为 16 个 LLM 条件。树模型的 Recall 较低，而 SVM/LLM 靠近多数类基线。

3.5 审查过程特征消融

full 特征揭示了审查过程信息对不同模型的作用。人类 test 的四个模型获得约 0.05–0.07 的 F1 增益；AI 侧 RF、XGBoost 和 LightGBM 分别增加 0.109、0.071 和 0.043，SVM 下降 0.156（图 4）。加入过程变量后，AI 侧四个模型的 F1 为 0.665–0.694，与人类 test 仍相差 0.176–0.203。

审查过程变量记录 PR 提交后的交互，其增益刻画后验信息的诊断价值。三个树模型从这些信号中获得部分恢复；SVM 的大幅反向变化进一步显示其 pre-review 结果对输入分布和决策边界较为敏感。




图 4 加入审查过程特征前后的 F1 变化。纵轴为 $\Delta F1 = F1_{full} - F1_{pre}$ ；蓝、红、绿分别表示人类 test、AI 代码和匹配人类对照。AI 侧三个树模型获得正增益，SVM 明显下降。full 特征用于诊断后验过程信息的作用。

3.6 审查意见生成结果与样例

16 个生成条件均处于低词面重合区间：BLEU 为 0.560–1.463（0–100 量纲），ROUGE-1 为 0.0466–0.0648，ROUGE-2 为 0.0104–0.0240，ROUGE-L 为 0.0429–0.0589。AI 侧平均 BLEU 和 ROUGE-L 分别为 0.991 和 0.0495，人类侧分别为 0.965 和 0.0426。两组均值接近，全部结果集中在低重合区间，单一参考文本对审查意见表达空间的覆盖有限。

Airflow PR #63368 展示了词面指标与内容质量之间的间隙。人工意见关注 detail 缺失以及 None 与空容器的区分；C2-P3 生成意见建议将真值判断改为显式的 is not None 判断，确保空列表或空字典仍能正确显示。模型定位了相同边界条件并给出具体修改，表达形式与参考意见存在差异。该样例说明生成评价还需要覆盖问题定位、事实正确性和建议可执行性。

3.7 上下文敏感度分析

上下文对两个任务产生了不同影响。AI 分类 F1 从 C1 的 0.8488 变为 C4 的 0.8480，变化为 -0.00088 ；人类侧变化为 $+0.00901$ （图 5a）。AI 生成 ROUGE-L 从 0.0459 增至 0.0506，增益为 $+0.00474$ ；人类侧从 0.0469 降至 0.0417，变化为 -0.00518 （图 5b）。新增 PR 描述和 Commit 信息对分类几乎没有影响，对 AI 审查意见生成带来小幅增益。

C2 或 C3 在部分条件下优于 C4，上下文收益并未随输入长度单调增长。实验六可进一步比较信息选择、结构化组织和任务相关性，定位真正有效的上下文成分。




图 5 从 C1 到 C4 的上下文敏感度。每个点为同一上下文下四种 Prompt 的指标均值。**a**, Merge Prediction F1; AI 的 C4-C1 变化约为 -0.001 ，人类约为 $+0.009$ 。**b**, Review Comment Generation ROUGE-L; AI 的变化约为 $+0.005$ ，人类约为 -0.005 。生成对照与人类锚点复用同一批样本，故两条曲线重合。图中为描述性点估计。

3.8 错误案例归因与 AI 代码审查挑战

C1-P1 的五个典型误判均为假阳性：PR 实际未合并，模型预测合并（图 6）。这些 pandas diff 包含明确的 issue 编号、解释性注释、边界条件处理或新增测试。pandas #65951 增加了前导零与大数转换测试，pandas #66061 在解析阶段增加类型检查并解释错误来源。局部 diff 呈现出目标明确、注释充分和测试完整的表面特征，模型据此作出偏乐观判断。

错误方向揭示了局部代码质量与最终合并状态之间的信息缺口。issue 关系、PR 讨论、仓库状态和维护流程共同影响合并结果，单个 diff 缺少这些信号。后续分析可将技术质量与最终合并状态拆分标注，并补充项目级上下文。

Five selected diff-only errors are false positives on surface-complete AI PRs




图 6 五个典型 diff-only 分类错误。**a**，五例均为假阳性，即模型预测合并但实际未合并；**b**，对应的 pandas PR 编号、预测、真实标签和上下文。图中包含按程序抽取的五个代表性案例；归因依据为 diff 的表面特征，未合并的流程原因仍需结合 PR 时间线人工核验。

3.9 综合结论与实验思考

1. AI 生成代码与人类编写代码有哪些本质区别？ 本实验观察到两类直接影响代码审查的差异。AI PR 在仓库组成和合并率上形成了独立分布；典型 diff 还表现出较高的表面规范性，常见明确注释、issue 引用和配套测试。模型在人类代码上建立的局部特征规律由此发生偏移，代码外观与最终合并状态之间的联系也随之减弱。

2. 为什么已有模型在 AI 生成代码上的性能可能下降？ 主结果与匹配对照共同指向训练-测试分布偏移。错误案例显示，规范的注释、测试和边界处理会增强局部 diff 的可合并外观，而最终合并还取决于 issue 关系、维护决策和仓库状态。模型输入缺少这些项目级信号，局部特征对合并标签的解释力随之下降。

3. 哪类模型对 AI 生成代码具有更好的泛化能力？为什么？ 树模型在合并预测上的泛化最弱，其 F1 和 Recall 均出现直接下降。SVM 与 LLM 保持了较高 F1，但二者靠近多数类基线，主要表现为持续预测“合并”。LLM 的相对优势体现在输入适配：无需更新权重即可处理四种上下文，并在审查意见生成中获得小幅上下文增益；分类结果仍由合并偏向主导。

4. AI 生成代码是否需要新的评价指标？为什么？ 需要扩展评价指标体系。分类任务应加入未合并类 Recall、balanced accuracy、MCC、PR-AUC 和校准误差，以识别高合并率下的决策偏向。生成任务应评价问题定位正确性、事实一致性、建议可执行性、严重程度和覆盖率，并用具体案例连接自动指标与实际审查价值。

5. 本实验发现了哪些 AI 生成代码特有的代码审查挑战？ 本实验识别出五类挑战：高合并率放大多数类预测的 F1；表面完整的代码容易形成假阳性；局部 diff 缺少项目级约束；最终合并标签混合技术质量与维护流程；单一参考文本难以覆盖开放式审查意见。对应的改进方向包括上下文选择、标签重构、类别平衡和多维生成评价。

最终结论。 固定模型迁移揭示了 AI 代码审查中的两种核心偏差：树模型丢失召回能力，SVM 与 LLM 倾向预测“合并”。审查意见生成的 BLEU/ROUGE 整体较低，C4 相对 C1 的 ROUGE-L 增益约为 0.005。实验六可据此引入仓库、issue 和调用关系上下文，校正合并预测的类别偏向，并建立面向正确性与可操作性的生成评价。

本实验的解释范围由数据与协议共同限定：AI 标签采用启发式规则，样本集中于少数 Python 仓库，匹配对照的标签比例仍有差异，评估使用单一固定划分，实验三深度学习模型尚未实现，错误案例也缺少完整 PR 时间线标注。结论适用于当前数据集和模型配置，跨工具、跨语言和跨仓库的推广需要独立验证。

四、实验中遇到的问题总结

要求：主要阐述实验过程中遇到的问题如何解决的。

4.1 AI 代码样本的筛选

实验一中的 `is_ai_code` 标记来自作者、提交信息和文本提示等启发式信号，不能完全等同于人工确认的 AI 生成代码。为减少不确定性，本实验保留标记的触发依据，并按照两个任务的输入要求进一步筛选样本：合并预测要求包含有效的 Python patch，审查意见生成要求存在可用的行内评论。这样能够保证输入和真值满足评估要求，同时在结论中明确 AI 标签仍可能存在误差。

4.2 模型输入与特征的一致性

已有模型直接迁移到 AI PR 时，必须与原实验保持相同的特征顺序、标准化方式、上下文组织和 Prompt 设置，否则性能差异可能来自实现变化。对此，传统机器学习分支复用了实验二保存的特征定义、标准化器和模型权重，LLM 分支沿用了实验四的推理参数与输出格式，并使用固定随机种子和缓存记录样本及结果，从而保证人类代码与 AI 代码之间的比较具有一致口径。

4.3 类别不平衡与生成指标解释

AI 合并预测样本中已合并 PR 占比较高，只报告 F1 容易高估持续预测“合并”的模型。实验中因此同时检查 Precision、Recall 和多数类基线，以区分真正的判别能

力与类别偏向。审查意见生成也存在类似问题：一条代码改动可能对应多种合理意见，BLEU 和 ROUGE 的低词面重合不能直接说明意见无效。因此，结果分析同时结合具体生成样例，避免仅依赖单一自动指标得出结论。

五、实验体会

5.1 对模型泛化能力的认识

本实验说明，在人类代码上表现较好的模型不一定能够直接适用于 AI 生成代码。三个树模型在 AI 数据上的召回率明显下降，而 SVM 和 LLM 虽保持较高 F1，却表现出偏向预测“合并”的现象。这使我认识到，评价模型泛化能力不能只比较一个总体分数，还应结合数据分布、错误方向和简单基线进行判断。

5.2 对代码审查上下文的认识

仅凭局部 diff 很难完整判断 PR 是否应当合并，因为最终结果还会受到 issue 关系、项目规范和维护流程等因素影响。实验中的错误案例表明，注释完整、测试充分的改动仍可能未被合并。由此可见，AI 代码审查不仅需要理解代码本身，还需要选择与任务相关的软件工程上下文；上下文也并非越多越好，而应关注信息是否真正有助于当前判断。

5.3 对后续实验的启发

通过本实验，我进一步理解了实验一至实验四所构建数据和模型之间的衔接关系，也明确了实验六的改进方向。后续可以补充仓库级、issue 级和调用关系上下文，并采用更关注类别平衡、事实正确性和建议可操作性的评价方法。整体而言，本实验不仅比较了已有模型在新数据上的表现，也揭示了 AI 生成代码给数据标注、模型迁移和结果评价带来的实际挑战。

指导教师评语：

日期：